



TALENTO TECH REGIÓN 2

NIVEL EXPLORATORIO

PROYECTO: DATOS QUE IMPULSAN LA TRANSICIÓN

EQUIPO ECO ANALYTICS

MANUEL ALEJANDRO SÁNCHEZ

VALENTINA CUESTAS MEJÍA

LEYDI CARDONA MORALES

PEREIRA, AGOSTO 2025

INTRODUCCIÓN

La introducción de vehículos eléctricos e híbridos en Colombia ha sido respaldada por un conjunto de leyes y normativas que promueven la sostenibilidad y la transición hacia un modelo de transporte más ecológico. La **Ley 1964 de 2019**, en particular, establece una serie de beneficios para estos vehículos, entre los que se incluyen incentivos significativos como una reducción del impuesto vehicular a menos del 1%, la rebaja del 10% en el costo del SOAT, una revisión técnico-mecánica simplificada, la eliminación de restricciones en el pico y placa, así como la asignación de espacios de parqueo preferencial. Además, se fomenta la creación de infraestructura para la electrificación pública y la implementación de sistemas de carga adecuados.

Estas políticas se complementan con la **Ley 1116 de 2017** y el **Decreto 1116 de 2017**, que reducen el arancel de importación al 5% y el IVA al 5% para los vehículos eléctricos e híbridos, facilitando su acceso y promoción en el mercado nacional. De igual forma, el **Decreto 2051 de 2019** refuerza estos incentivos fiscales, incentivando la importación de este tipo de vehículos. En adición, el **Decreto 40-2022** extiende incentivos fiscales por 10 años, incluyendo beneficios en el IVA, el IPRIMA, el SOAT y el impuesto de renta, así como medidas que promueven el desarrollo de la infraestructura necesaria para la carga de vehículos eléctricos. Estas normativas reflejan el compromiso del país con la sostenibilidad y el impulso de tecnologías limpias en el sector del transporte.

El análisis de datos en este contexto permite identificar la relación entre la adopción de este tipo de vehículos y los incentivos establecidos por el marco legal, generando evidencia cuantitativa sobre su efectividad. Y de cierta manera comprender cómo ha evolucionado el número de vehículos eléctricos e híbridos en relación con estas medidas normativas en la toma de decisiones al obtener un vehículo de este tipo, además del diseño de nuevas políticas públicas y la consolidación de una movilidad más sostenible en el país.

En este proyecto se realizará un análisis de la base de datos de vehículos eléctricos e híbridos registrados a nivel nacional, con especial énfasis en la región del Eje Cafetero, con el fin de explorar las tendencias regionales, comparar la dinámica local con el panorama nacional, evaluar cómo las políticas vigentes están generando reducciones en las emisiones de CO₂ para fortalecer una transición energética más verde, además de medir si los incentivos normativos realmente impulsan la adopción de Vehículos Eléctricos e Híbridos y cómo contribuyen a los objetivos de movilidad sostenible en el país específicamente en el Eje cafetero.

OBJETIVO GENERAL

Analizar el impacto de los incentivos normativos establecidos en la Ley 1964 de 2019 sobre la adopción de vehículos eléctricos e híbridos en el Eje Cafetero, con el fin de evaluar la efectividad de estas políticas públicas en la promoción de una movilidad sostenible.

OBJETIVOS ESPECÍFICOS

1. Identificar los principales incentivos normativos y económicos contemplados en la Ley 1964 de 2019 y su aplicabilidad en el contexto regional del Eje Cafetero.
2. Recopilar y analizar datos sobre el crecimiento del parque automotor eléctrico e híbrido en los departamentos de Caldas, Risaralda y Quindío durante los últimos años.
3. Determinar los factores que limitan o favorecen la adopción de vehículos eléctricos e híbridos en la región, incluyendo aspectos como el conocimiento de la ley, la infraestructura de carga y el costo de los vehículos.
4. Proponer recomendaciones orientadas al fortalecimiento de las políticas de movilidad sostenible en el Eje Cafetero, basadas en los hallazgos del estudio.

DESCRIPCIÓN DEL PROYECTO

1.IDENTIFICACIÓN DEL PROBLEMA

El sector transporte en Colombia sigue siendo uno de los mayores emisores de gases de efecto invernadero contribuyendo significativamente a la contaminación del aire, particularmente en zonas urbanas. Esta problemática ha generado una creciente necesidad de adoptar alternativas más sostenibles, como los vehículos eléctricos e híbridos, que ofrecen una solución eficaz para reducir la huella de carbono y mejorar la calidad del aire.

A pesar de los incentivos legales establecidos por el Estado, como la **Ley 1964 de 2019**, que busca promover el uso de tecnologías de bajas y cero emisiones, la adopción de vehículos eléctricos e híbridos en Colombia continúa siendo limitada. Aunque se han implementado medidas como la exención de restricciones como el pico y placa, descuentos en el impuesto vehicular, y la reducción de tarifas para la revisión técnico-mecánica, la adopción de estas tecnologías sigue siendo lenta.

Uno de los principales desafíos es el desconocimiento generalizado de los beneficios y estímulos legales entre los ciudadanos y los actores del sector automotriz. Además, persisten barreras como el elevado costo de adquisición, la falta de infraestructura de carga adecuada, y la resistencia cultural a cambiar las prácticas tradicionales de transporte.

Para abordar esta cuestión, es necesario realizar un análisis detallado sobre el impacto real de estas políticas, con un enfoque particular en el **Eje Cafetero**, una región que, aunque cuenta con un gran potencial para el uso de vehículos eléctricos e híbridos, enfrenta desafíos específicos en términos de infraestructura y conciencia pública.

El análisis se basa en los datos disponibles a través de la plataforma **Datos Abiertos del Gobierno de Colombia**, donde se consultó el número de vehículos eléctricos e híbridos registrados a nivel nacional. Esta base de datos se utilizó para entender la penetración de estos vehículos en el país y, específicamente, en la región del Eje Cafetero.

Este proyecto, al centrarse en la región del Eje Cafetero, busca identificar tendencias, barreras y oportunidades para una mayor adopción de vehículos eléctricos e híbridos, y evaluar la efectividad de los incentivos gubernamentales establecidos en las normativas vigentes. Con base en los datos disponibles, se podrá determinar si las políticas públicas están logrando su objetivo de promover la movilidad sostenible en esta zona del país.

2. RECOLECCIÓN DE DATOS:

Se consultó en la página de datos abiertos del Gobierno Digital MinTIC, tomamos el conjunto de datos Número de Vehículos eléctricos e híbridos registrados a nivel Nacional, a continuación se relaciona el link de la página : https://www.datos.gov.co/Transporte/Numero-de-Veh-culos-El-ctricos-Hibridos/7qfh-tnkr3/about_data

Este conjunto de datos contiene 56545 registros y cuenta con 22 columnas:

GOV.CO

datos Abiertos

Buscar

Inicio

Descubre

Publica

Visualiza

Herramientas

Noticias

Usos

Calidad

0

Español

Iniciar sesión

Acciones

Exportar

Información sobre esta Categoría

Datos

Contenido Relacionado

Numero de Vehículos Eléctricos - Híbridos

Transporte

Vehículos eléctricos - Híbridos

Última Actualización
20 de abril de 2024

Datos suministrados por
Ministerio de Transporte

Información sobre este conjunto de datos

Actualizado
20 de abril de 2024

Última actualización de los datos
14 de diciembre de 2022

Fecha de creación
17 de marzo de 2022

Vistas
7.862

Descargas
2.497

¿Utilidad los datos
Ministerio de Transporte

Preparado de conjunto de datos
Ministerio de Transporte

Información de la Entidad

Departamento
Bogotá D.C.

Municipio
Bogotá D.C.

Nombre de la Entidad
Ministerio de Transportes

Orden
Nacional

Área o dependencia
Grupo de tecnología de la información y comunicaciones

Sector
Transporte

Información de Datos

Idioma
Español

Cobertura Geográfica
Nacional

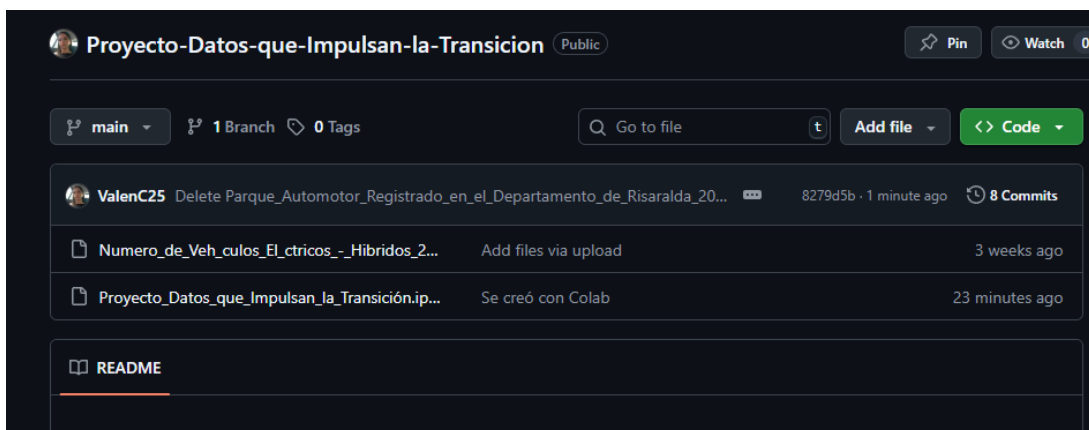
Frecuencia de Actualización
Mensual

Fecha Emisión (aaaa-mm-dd)
17/03/2022

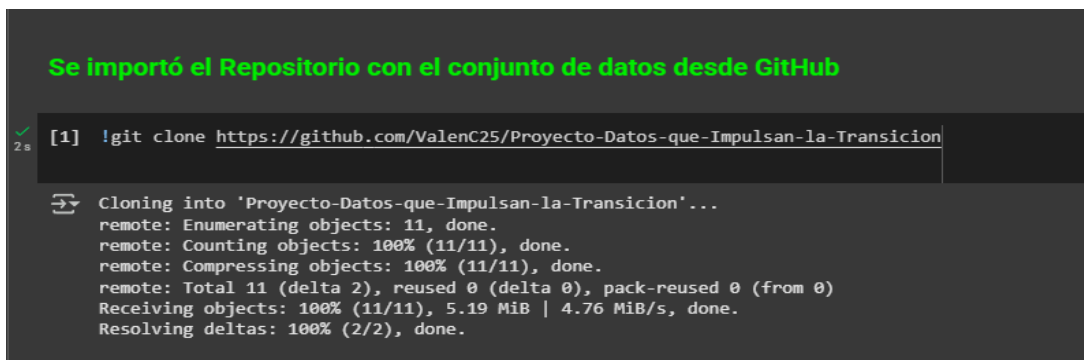
Temas

Categoría
Transporte

Se seleccionaron y se descargaron los conjuntos de datos, luego se procede a la creación y desarrollo del proyecto en el repositorio GitHub compartido con todos los integrantes del equipo.



A continuación, se importó el repositorio con el conjunto de datos ya mencionado:



3. EXPLORACIÓN Y LIMPIEZA DE DATOS:

Se importan las bibliotecas de Pandas y Numpy, se vincula el conjunto de datos vehículos eléctricos e híbridos registrados a nivel nacional con: 56545 rows, 22 cols.



| | | | | | | | | | | | | | |
|-------|-----------|--------|------|---------------------------|------|-----------|-----------|------------|----------|-----------------|-----|-----------|---------------|
| 3 | ELECTRICO | ACTIVO | 2021 | 08/10/2022 12:00:00 AM | 2022 | AUTOMOVIL | CAMIONETA | Público | DONGFENG | DFA5030XXYABEV7 | ... | CARGA | ST M |
| 4 | ELECTRICO | ACTIVO | 2022 | 10/25/2021 12:00:00 AM | 2021 | AUTOMOVIL | CAMIONETA | Particular | BYD | SONG PRO EV | ... | NaN | STF CUN |
| ... | ... | ... | ... | ... | ... | ... | ... | ... | ... | ... | ... | ... | ... |
| 56540 | GASO ELEC | ACTIVO | 2023 | 10/06/2022 12:00:00 AM | 2022 | AUTOMOVIL | CAMIONETA | Particular | MAZDA | CX-30 | ... | PASAJEROS | STRIA |
| 56541 | GASO ELEC | ACTIVO | 2023 | 10/07/2022 12:00:00 AM | 2022 | AUTOMOVIL | CAMIONETA | Particular | MAZDA | CX-30 | ... | NaN | SEC MUNICI |
| 56542 | GASO ELEC | ACTIVO | 2023 | 10/12/2022 12:00:00 AM | 2022 | AUTOMOVIL | CAMIONETA | Particular | MAZDA | CX-30 | ... | NaN | ST MCF |
| 56543 | GASO ELEC | ACTIVO | 2023 | 09/30/2022 12:00:00 AM | 2022 | AUTOMOVIL | CAMIONETA | Particular | MAZDA | CX-30 | ... | PASAJEROS | SDM - I |
| 56544 | GASO ELEC | ACTIVO | 2022 | 11/26/2022 12:00:00 AM | 2022 | AUTOMOVIL | CAMPERO | Particular | TOYOTA | RAV 4 | ... | PASAJEROS | STRIA |

56545 rows x 22 columns

Luego se utiliza el método `info()` con la biblioteca Pandas, para obtener un resumen conciso de un DataFrame o Series, mostrando el tipo de datos del índice y las columnas, el recuento de valores no nulos y el uso de memoria, lo cual ayuda a entender la estructura y estado de los datos.

```

Se utilizó el método info() para el primer conjunto de datos (data), para visualizar un resumen conciso del DataFrame,
mostrando información sobre las columnas, tipos de datos, valores no nulos y uso de memoria

[3] data.info()

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 56545 entries, 0 to 56544
Data columns (total 22 columns):
 #   Column                Non-Null Count  Dtype  
---  --
 0   COMBUSTIBLE            56545 non-null  object 
 1   ESTADO                 56545 non-null  object 
 2   MODELO                  56545 non-null  int64  
 3   FECHA_REGISTRO          56545 non-null  object 
 4   AÑO_REGISTRO            56545 non-null  int64  
 5   CLASIFICACION           56545 non-null  object 
 6   CLASE                   56545 non-null  object 
 7   SERVICIO                56545 non-null  object 
 8   MARCA                   56545 non-null  object 
 9   LINEA                   56545 non-null  object 
10  CARROCERIA              56545 non-null  object 
11  CILINDRAJE              53054 non-null  float64 
12  MODALIDAD               36663 non-null  object 
13  ORGANISMO_TRANSITO      56545 non-null  object 
14  MUNICIPIO               56545 non-null  object 
15  DEPARTAMENTO             56545 non-null  object 
16  CAPACIDAD_CARGA          6220 non-null   float64 
17  CAPACIDAD_PASAJEROS     1311 non-null   float64 
18  PESO                     54116 non-null  float64 
19  POTENCIA                 55548 non-null  float64 
20  EJES                     54473 non-null  float64 
21  CANTIDAD                 56545 non-null  int64  
dtypes: float64(6), int64(3), object(13)

```

Se emplea el método `shape` en el conjunto de datos (`data`) para visualizar y conocer las dimensiones del DataFrame y verificar si hay campos nulos o sin resultados.

Adicionalmente, se usó la función `unique()` de la Biblioteca Python Pandas para obtener los valores únicos en una columna del DataFrame, lo que permitió obtener una visión general de los diferentes valores del conjunto de datos.

```

Se utilizó la función .shape para conocer las dimensiones del dataframe y verificar si hay campos nulos

[153] data.shape

(56545, 22)

```

Se utilizó el método unique() para verificar cuantos tipos de combustible, la clase, la clasificación, el año de registro y la fecha de registro, en la que están distribuidos los vehículos en el conjunto de datos

```
data['FECHA_REGISTRO'].unique()
array(['06/30/2022 12:00:00 AM', '10/21/2022 12:00:00 AM',
      '09/28/2015 12:00:00 AM', ..., '11/06/2018 12:00:00 AM',
      '11/24/2018 12:00:00 AM', '04/27/2019 12:00:00 AM'], dtype=object)

[45] data['COMBUSTIBLE'].unique()
array(['ELECTRICO', 'GASO ELEC', 'DIES ELEC'], dtype=object)

[46] data['CLASE'].unique()
array(['BUS', 'CAMIONETA', 'MOTOCICLETA', 'AUTOMOVIL', 'MOTOTRICICLO',
      'MOTOCARRO', 'CUADRICICLO', 'CAMION', 'TRICIMOTO', 'MICROBUS',
      'CUATRIMOTO', 'TRACTOCAMION', 'CAMPERO'], dtype=object)

[47] data['CLASIFICACION'].unique()
array(['AUTOMOVIL', 'MOTO', 'MOTOCARRO'], dtype=object)

[48] data['AÑO_REGISTRO'].unique()
array([2022, 2015, 2021, 2019, 2020, 2014, 2016, 2013, 2018, 2012, 2017,
      2010, 2011])
```

- Fecha de registro: los años de registro con los meses
- Se identifican los tres tipos Combustibles: [Electrico, Gasolina -Eléctrico, Diesel - Electrico]
- La Clase de vehículos registrados en el conjunto de datos: 'Bus', 'Camioneta', 'Motocicleta', 'Automóvil', 'Moto Triciclo', 'Motocarro', 'Cuadriciclo', 'Camión', 'Tricimoto', 'Microbús', 'Cuatrimoto', 'Tractocamión', 'Campero'
- La Clasificación: ['Automóvil', 'Moto', 'Motocarro']
- Año de registro: ([2022, 2015, 2021, 2019, 2020, 2014, 2016, 2013, 2018, 2012, 2017, 2010, 2011])

A continuación, se agrupan los datos de la primera base en la columna COMBUSTIBLE con la función groupby() y se utiliza el método count() para saber cuántas veces aparece cada valor en la columna, se verifica que es muy útil cuando se necesita realizar un análisis de frecuencia de los datos, y así poder filtrar la información y realizar una limpieza del Dataframe por Departamentos para mejorar la visibilidad de los datos con los que se va a trabajar obteniendo como resultado 29 rows x 21 cols.

Se utilizó la función .groupby para agrupar los datos en la columna COMBUSTIBLE y el método count() para saber cuantas veces aparece cada valor en la columna

```
[9] data.groupby('COMBUSTIBLE').count()
```

| | ESTADO | MODELO | FECHA_REGISTRO | AÑO_REGISTRO | CLASIFICACION | CLASE | SERVICIO | MARCA | LINEA | CARRROCERIA | ... | MODALIDAD | ORGANISMO_TRANSITO | MUNICIPIO | DEPARTAMENTO |
|-------------|--------|--------|----------------|--------------|---------------|-------|----------|-------|-------|-------------|-----|-----------|--------------------|-----------|--------------|
| COMBUSTIBLE | | | | | | | | | | | | | | | |
| DIES ELEC | 1421 | 1421 | | 1421 | 1421 | 1421 | 1421 | 1421 | 1421 | 1421 | ... | 1100 | | 1421 | 1421 |
| ELECTRICO | 9574 | 9574 | | 9574 | 9574 | 9574 | 9574 | 9574 | 9574 | 9574 | ... | 6712 | | 9574 | 9574 |
| GASO ELEC | 45550 | 45550 | | 45550 | 45550 | 45550 | 45550 | 45550 | 45550 | 45550 | ... | 28851 | | 45550 | 45550 |

3 rows x 21 columns

Se filtro la información del dataframe por departamentos para tener una mejor visibilidad de los datos con los que vamos a trabajar

[10] data.groupby("DEPARTAMENTO").count()

| | Arauca | Archipiélago de San Andrés, Providencia | Atlántico | Bogotá D.C. | Bolívar | Boyacá | Caldas | Caquetá | Casanare | Norte de Santander | Quindío | Risaralda | Santander | Sucre | Tolima | Valle del Cauca |
|--|--------|---|-----------|-------------|---------|--------|--------|---------|----------|--------------------|---------|-----------|-----------|-------|--------|-----------------|
| | 8 | 8 | 8 | 8 | 8 | 8 | 8 | 8 | 8 | 8 | 8 | 8 | 8 | 8 | 8 | 8 |
| | 8 | 8 | 8 | 8 | 8 | 8 | 8 | 8 | 8 | 8 | 8 | 8 | 8 | 8 | 8 | 8 |
| | 846 | 846 | 846 | 846 | 846 | 846 | 846 | 846 | 846 | 846 | 846 | 846 | 846 | 846 | 846 | 846 |
| | 25507 | 25507 | 25507 | 25507 | 25507 | 25507 | 25507 | 25507 | 25507 | 25507 | 25507 | 25507 | 25507 | 25507 | 25507 | 25507 |
| | 225 | 225 | 225 | 225 | 225 | 225 | 225 | 225 | 225 | 225 | 225 | 225 | 225 | 225 | 225 | 225 |
| | 454 | 454 | 454 | 454 | 454 | 454 | 454 | 454 | 454 | 454 | 454 | 454 | 454 | 454 | 454 | 454 |
| | 750 | 750 | 750 | 750 | 750 | 750 | 750 | 750 | 750 | 750 | 750 | 750 | 750 | 750 | 750 | 750 |
| | 87 | 87 | 87 | 87 | 87 | 87 | 87 | 87 | 87 | 87 | 87 | 87 | 87 | 87 | 87 | 87 |
| | 83 | 83 | 83 | 83 | 83 | 83 | 83 | 83 | 83 | 83 | 83 | 83 | 83 | 83 | 83 | 83 |
| | 2350 | 2350 | 2350 | 2350 | 2350 | 2350 | 2350 | 2350 | 2350 | 2350 | 2350 | 2350 | 2350 | 2350 | 2350 | 2350 |
| | 304 | 304 | 304 | 304 | 304 | 304 | 304 | 304 | 304 | 304 | 304 | 304 | 304 | 304 | 304 | 304 |
| | 958 | 958 | 958 | 958 | 958 | 958 | 958 | 958 | 958 | 958 | 958 | 958 | 958 | 958 | 958 | 958 |
| | 679 | 679 | 679 | 679 | 679 | 679 | 679 | 679 | 679 | 679 | 679 | 679 | 679 | 679 | 679 | 679 |
| | 148 | 148 | 148 | 148 | 148 | 148 | 148 | 148 | 148 | 148 | 148 | 148 | 148 | 148 | 148 | 148 |
| | 431 | 431 | 431 | 431 | 431 | 431 | 431 | 431 | 431 | 431 | 431 | 431 | 431 | 431 | 431 | 431 |
| | 3222 | 3222 | 3222 | 3222 | 3222 | 3222 | 3222 | 3222 | 3222 | 3222 | 3222 | 3222 | 3222 | 3222 | 3222 | 3222 |

29 rows x 21 columns

Considerando todas las columnas disponibles, se procede a evaluar cada una para identificar si pueden aportar información útil al presente estudio. Del total de 22 columnas, se deja un nuevo total de 5 columnas, reduciendo el número de características o registros, pero conservando la información esencial. Esto ayuda a acelerar el análisis y el entrenamiento del modelo sin sacrificar la precisión.

Se seleccionan las columnas que contienen información relevante para el estudio, reduciendo así el tamaño del dataframe

```
data_estudio = data[["DEPARTAMENTO", "CLASE", "COMBUSTIBLE", "FECHA_REGISTRO", "AÑO_REGISTRO", ]]
```

| | DEPARTAMENTO | CLASE | COMBUSTIBLE | FECHA_REGISTRO | AÑO_REGISTRO |
|-------|--------------|-------------|-------------|------------------------|--------------|
| 0 | Bogotá D.C. | BUS | ELECTRICO | 06/30/2022 12:00:00 AM | 2022 |
| 1 | Risaralda | CAMIONETA | ELECTRICO | 10/21/2022 12:00:00 AM | 2022 |
| 2 | Caquetá | MOTOCICLETA | ELECTRICO | 09/28/2015 12:00:00 AM | 2015 |
| 3 | Cundinamarca | CAMIONETA | ELECTRICO | 08/10/2022 12:00:00 AM | 2022 |
| 4 | Cundinamarca | CAMIONETA | ELECTRICO | 10/25/2021 12:00:00 AM | 2021 |
| ... | ... | ... | ... | ... | ... |
| 56540 | Antioquia | CAMIONETA | GASO ELEC | 10/06/2022 12:00:00 AM | 2022 |
| 56541 | Cundinamarca | CAMIONETA | GASO ELEC | 10/07/2022 12:00:00 AM | 2022 |
| 56542 | Cauca | CAMIONETA | GASO ELEC | 10/12/2022 12:00:00 AM | 2022 |
| 56543 | Bogotá D.C. | CAMIONETA | GASO ELEC | 09/30/2022 12:00:00 AM | 2022 |
| 56544 | Antioquia | CAMPERO | GASO ELEC | 11/26/2022 12:00:00 AM | 2022 |

56545 rows x 5 columns

En el estudio se va a hacer énfasis en el Eje cafetero, para esto con la función groupby se crea un resumen de los datos mediante la fórmula, lo cual nos permite agrupar el eje datos_risaralda y agregar los valores asociados los cuales se consideran relevantes para el estudio que deseamos realizar obteniéndose como resultado 958 registros y 5 columnas para el departamento de Risaralda, a continuación se emplea el método info() mediante el cual se observa que no hay datos nulos.

Del conjunto de datos (data_estudio) se toman los datos de los vehículos de Risaralda

```
[15] grupos = data_estudio.groupby('DEPARTAMENTO')
      datos_risaralda = grupos.get_group('Risaralda')
      datos_risaralda
```

| | DEPARTAMENTO | CLASE | COMBUSTIBLE | FECHA_REGISTRO | AÑO_REGISTRO |
|-------|--------------|-------------|-------------|------------------------|--------------|
| 1 | Risaralda | CAMIONETA | ELECTRICO | 10/21/2022 12:00:00 AM | 2022 |
| 164 | Risaralda | AUTOMOVIL | ELECTRICO | 12/29/2020 12:00:00 AM | 2020 |
| 191 | Risaralda | CAMIONETA | ELECTRICO | 08/29/2022 12:00:00 AM | 2022 |
| 219 | Risaralda | MOTOCICLETA | ELECTRICO | 12/29/2020 12:00:00 AM | 2020 |
| 455 | Risaralda | CAMIONETA | ELECTRICO | 05/04/2022 12:00:00 AM | 2022 |
| ... | ... | ... | ... | ... | ... |
| 56321 | Risaralda | CAMPERO | GASO ELEC | 11/01/2022 12:00:00 AM | 2022 |
| 56400 | Risaralda | CAMIONETA | GASO ELEC | 10/12/2022 12:00:00 AM | 2022 |
| 56401 | Risaralda | CAMIONETA | GASO ELEC | 10/12/2022 12:00:00 AM | 2022 |
| 56402 | Risaralda | CAMIONETA | GASO ELEC | 10/05/2022 12:00:00 AM | 2022 |
| 56403 | Risaralda | CAMIONETA | GASO ELEC | 10/05/2022 12:00:00 AM | 2022 |

958 rows x 5 columns

Se utilizó el método info() para datos_risaralda, para visualizar un resumen conciso del DataFrame, mostrando información sobre las columnas, tipos de datos, valores no nulos y uso de memoria

```
[15] datos_risaralda.info()
```

```
<class 'pandas.core.frame.DataFrame'>
Index: 958 entries, 1 to 56403
Data columns (total 5 columns):
#   Column          Non-Null Count  Dtype
---  -
0   DEPARTAMENTO     958 non-null    object
1   CLASE            958 non-null    object
2   COMBUSTIBLE      958 non-null    object
3   FECHA_REGISTRO   958 non-null    object
4   AÑO_REGISTRO     958 non-null    int64
dtypes: int64(1), object(4)
memory usage: 77.2+ KB
```

De la misma manera se procede a aplicar la función groupby para el departamento de Caldas obteniéndose como resultado 750 registros y 5 columnas para datos_caldas, a continuación, se emplea el método info () mediante el cual se observa que no hay datos nulos.

▼ Del conjunto de datos (data_estudio) se toman los datos de los vehículos de Caldas

```

grupos = data_estudio.groupby('DEPARTAMENTO')
datos_caldas = grupos.get_group('Caldas')
datos_caldas

```

| | DEPARTAMENTO | CLASE | COMBUSTIBLE | FECHA_REGISTRO | AÑO_REGISTRO |
|-------|--------------|-------------|-------------|------------------------|--------------|
| 159 | Caldas | CAMIONETA | ELECTRICO | 03/28/2019 12:00:00 AM | 2019 |
| 296 | Caldas | AUTOMOVIL | ELECTRICO | 04/27/2016 12:00:00 AM | 2016 |
| 596 | Caldas | CUADRICICLO | ELECTRICO | 08/13/2019 12:00:00 AM | 2019 |
| 957 | Caldas | CUADRICICLO | ELECTRICO | 09/04/2019 12:00:00 AM | 2019 |
| 1077 | Caldas | AUTOMOVIL | ELECTRICO | 12/28/2021 12:00:00 AM | 2021 |
| ... | ... | ... | ... | ... | ... |
| 56286 | Caldas | CAMPERO | GASO ELEC | 09/29/2022 12:00:00 AM | 2022 |
| 56380 | Caldas | CAMIONETA | GASO ELEC | 10/04/2022 12:00:00 AM | 2022 |
| 56396 | Caldas | CAMPERO | GASO ELEC | 10/07/2022 12:00:00 AM | 2022 |
| 56477 | Caldas | CAMPERO | GASO ELEC | 11/16/2022 12:00:00 AM | 2022 |
| 56537 | Caldas | CAMIONETA | GASO ELEC | 10/10/2022 12:00:00 AM | 2022 |

750 rows × 5 columns

▼ Se utilizó el método info() para datos_caldas, para visualizar un resumen conciso del DataFrame, mostrando información sobre las columnas, tipos de datos, valores no nulos y uso de memoria

```

[17] datos_caldas.info()

```

```

<class 'pandas.core.frame.DataFrame'>
Index: 750 entries, 159 to 56537
Data columns (total 5 columns):
#   Column          Non-Null Count  Dtype
---  ---
0   DEPARTAMENTO     750 non-null    object
1   CLASE            750 non-null    object
2   COMBUSTIBLE      750 non-null    object
3   FECHA_REGISTRO  750 non-null    object
4   AÑO_REGISTRO     750 non-null    int64
dtypes: int64(1), object(4)
memory usage: 51.3+ KB

```

Se procede a aplicar la función groupby para el departamento de Quindío obteniéndose como resultado 304 registros y 5 columnas para datos_quindio, a continuación, se emplea el método info () mediante el cual se observa que no hay datos nulos.

✓ Del conjunto de datos (data_estudio) se toman los datos de los vehículos de Quindio

```

grupos = data_estudio.groupby('DEPARTAMENTO')
datos_quindio = grupos.get_group('Quindio')
datos_quindio

```

| | DEPARTAMENTO | CLASE | COMBUSTIBLE | FECHA_REGISTRO | AÑO_REGISTRO |
|-------|--------------|-------------|-------------|------------------------|--------------|
| 37 | Quindio | CAMIONETA | ELECTRICO | 12/03/2020 12:00:00 AM | 2020 |
| 2151 | Quindio | CUADRICICLO | ELECTRICO | 04/22/2019 12:00:00 AM | 2019 |
| 3843 | Quindio | MOTOCICLETA | ELECTRICO | 08/05/2016 12:00:00 AM | 2016 |
| 3909 | Quindio | AUTOMOVIL | ELECTRICO | 06/05/2018 12:00:00 AM | 2018 |
| 3960 | Quindio | AUTOMOVIL | ELECTRICO | 07/01/2015 12:00:00 AM | 2015 |
| ... | ... | ... | ... | ... | ... |
| 55629 | Quindio | CAMIONETA | GASO ELEC | 07/26/2022 12:00:00 AM | 2022 |
| 55750 | Quindio | CAMIONETA | GASO ELEC | 08/19/2022 12:00:00 AM | 2022 |
| 55884 | Quindio | CAMIONETA | GASO ELEC | 08/24/2022 12:00:00 AM | 2022 |
| 56329 | Quindio | AUTOMOVIL | GASO ELEC | 11/17/2022 12:00:00 AM | 2022 |
| 56492 | Quindio | AUTOMOVIL | GASO ELEC | 11/25/2022 12:00:00 AM | 2022 |

304 rows x 5 columns

✓ Se utilizó el método info() para datos_quindio, para visualizar un resumen conciso del DataFrame, mostrando información sobre las columnas, tipos de datos, valores no nulos y uso de memoria

```

datos_quindio.info()

```

```

<class 'pandas.core.frame.DataFrame'>
Index: 304 entries, 37 to 56492
Data columns (total 5 columns):
 #   Column          Non-Null Count  Dtype
---  -
 0   DEPARTAMENTO     304 non-null    object
 1   CLASE            304 non-null    object
 2   COMBUSTIBLE      304 non-null    object
 3   FECHA_REGISTRO   304 non-null    object
 4   AÑO_REGISTRO     304 non-null    int64
dtypes: int64(1), object(4)
memory usage: 22.4+ KB

```

Se utilizó el método info () en general se empleó para cada uno de los datos creados, para visualizar un resumen conciso del DataFrame, mostrando información sobre las columnas, tipos de datos, valores no nulos y uso de memoria

A continuación, se emplea la función pandas.concat (Unir DataFrame). Esta función se utiliza en la librería Pandas para combinar los tres Dataframe creados por departamento anteriormente, obteniendo como resultado un total de 2012 datos que son los vehículos eléctricos e híbridos registrados para los Departamentos de Risaralda, Caldas y Quindío, y se aplica nuevamente el método info (), luego se realiza un conteo de los vehículos registrados por cada año.

- ▼ A continuación para unir o concatenar las tres departamentos que son los datos sobre los cuales trabajaremos se emplea el metodo `pd.concat()`

```
[20] data_eje = pd.concat([datos_quindio, datos_caldas, datos_risaralda])
data_eje
```

| | DEPARTAMENTO | CLASE | COMBUSTIBLE | FECHA_REGISTRO | AÑO_REGISTRO |
|-------|--------------|-------------|-------------|------------------------|--------------|
| 37 | Quindio | CAMIONETA | ELECTRICO | 12/03/2020 12:00:00 AM | 2020 |
| 2151 | Quindio | CUADRICICLO | ELECTRICO | 04/22/2019 12:00:00 AM | 2019 |
| 3843 | Quindio | MOTOCICLETA | ELECTRICO | 08/05/2016 12:00:00 AM | 2016 |
| 3909 | Quindio | AUTOMOVIL | ELECTRICO | 06/05/2018 12:00:00 AM | 2018 |
| 3960 | Quindio | AUTOMOVIL | ELECTRICO | 07/01/2015 12:00:00 AM | 2015 |
| ... | ... | ... | ... | ... | ... |
| 56321 | Risaralda | CAMPERO | GASO ELEC | 11/01/2022 12:00:00 AM | 2022 |
| 56400 | Risaralda | CAMIONETA | GASO ELEC | 10/12/2022 12:00:00 AM | 2022 |
| 56401 | Risaralda | CAMIONETA | GASO ELEC | 10/12/2022 12:00:00 AM | 2022 |
| 56402 | Risaralda | CAMIONETA | GASO ELEC | 10/05/2022 12:00:00 AM | 2022 |
| 56403 | Risaralda | CAMIONETA | GASO ELEC | 10/05/2022 12:00:00 AM | 2022 |

2012 rows x 5 columns

- ▼ Se utilizó el método `info()` para `data_eje`, para visualizar un resumen conciso del DataFrame, mostrando información sobre las columnas, tipos de datos, valores no nulos y uso de memoria

```
[21] data_eje.info()
```

```
<class 'pandas.core.frame.DataFrame'>
Index: 2012 entries, 37 to 56403
Data columns (total 5 columns):
#   Column          Non-Null Count  Dtype
---  ---
0   DEPARTAMENTO     2012 non-null  object
1   CLASE           2012 non-null  object
2   COMBUSTIBLE     2012 non-null  object
3   FECHA_REGISTRO  2012 non-null  object
4   AÑO_REGISTRO    2012 non-null  int64
dtypes: int64(1), object(4)
memory usage: 158.9+ KB
```

- ▼ Se contaron los vehículos registrados por año

```
[22] contar_años = data_eje['AÑO_REGISTRO'].value_counts().sort_index()
contar_años
```

| | count |
|--------------|-------|
| AÑO_REGISTRO | |
| 2011 | 2 |
| 2014 | 1 |
| 2015 | 14 |
| 2016 | 20 |
| 2017 | 7 |
| 2018 | 20 |
| 2019 | 81 |
| 2020 | 129 |
| 2021 | 637 |
| 2022 | 1101 |

dtype: int64

Se utiliza el método `value_counts()` para conocer cuántas veces se repite cada dato en la columna año, filtre el número de vehículos registrados por año en el eje cafetero y los devuelva ordenados, luego se crea el gráfico de barras para tener una mejor visualización de los datos.


Se filtró por número de Vehículos Registrados por Año en Eje Cafetero

```
[51] contar_años = data_eje['AÑO_REGISTRO'].value_counts().sort_index()

# Creación del gráfico de barras
plt.figure(figsize=(12, 6))
barras = plt.bar(contar_años.index, contar_años.values, color = "green", alpha = 0.5) #Se define el tamaño de las barras para los índices

plt.xlabel('Año de Registro')
plt.ylabel('Número de Vehículos')
plt.title('Número de Vehículos Registrados por Año en Eje Cafetero')
plt.xticks(contar_años.index)
plt.grid(axis='y', linestyle='--', color = 'green') # muestra o oculta líneas de cuadrícula en un gráfico
plt.bar_label(barras, padding=3) #Muestra los índices

plt.show()
```



Gráfica 1. Número de Vehículos en el eje cafetero desde 2018 a 2022

De acuerdo a la cantidad de datos evidenciados por año para los tres departamentos del eje cafetero, se evidenció que en los primeros años de 2011 a 2017 no hay suficiente información que permita realizar análisis adecuado, afectando medidas de tendencia y generando datos atípicos en diagramas de dispersión, por este motivo se procedió a realizar un filtro con los 5 últimos años de 2018 a 2022 donde se observa los datos más significativos y se realiza gráfico con la información filtrada.

```
[ ] contar_años_filtrado = contar_años[contar_años.index >= 2018]
contar_años_filtrado
```

| AÑO_REGISTRO | count |
|--------------|-------|
| 2018 | 20 |
| 2019 | 81 |
| 2020 | 129 |
| 2021 | 637 |
| 2022 | 1101 |


dtype: int64

▼ Se realiza el gráfico con la información filtrada

```
plt.figure(figsize=(5, 6))
barras = plt.bar(contar_años_filtrado.index, contar_años_filtrado.values, color = "green", alpha = 0.5)

plt.xlabel('Año de Registro')
plt.ylabel('Número de Vehículos')
plt.title('Número de Vehículos Registrados por Año en Eje Cafetero')
plt.xticks(contar_años_filtrado.index)
plt.grid(axis='y', linestyle='--', color = 'green') # muestra o oculta líneas de cuadrícula en un gráfico
plt.bar_label(barras, padding=3) #Muestra los índices

plt.show()
```



Gráfica 2. Número de Vehículos en el eje cafetero desde 2018 a 2022


Del DataFrame data_eje se filtran los vehículos por clase y se crea gráfico.

Se filtraron los vehículos por clase

```
[52] clase_contar = data_eje['CLASE'].value_counts()

plt.figure(figsize=(12, 6))
barras = plt.bar(clase_contar.index, clase_contar.values, color = "green", alpha = 0.5)
plt.xlabel('Clase de Vehículo')
plt.ylabel('Número de Vehículos')
plt.title('Distribución de Clases de Vehículos en Eje Cafetero')
plt.xticks(rotation=45, ha='right')
plt.grid(axis='y', linestyle='--', color= 'green')
plt.tight_layout() #Ajustar el diseño para evitar que las etiquetas se superpongan
plt.bar_label(barras, padding=3)

plt.show()
```



Gráfica 3. Distribución de clases de Vehículos

De acuerdo a la cantidad de datos evidenciados por clase de vehículos, se evidencia que los vehículos, camioneta, automóvil y campero, son los que más cuentan con combustible híbrido y eléctrico, se procede a realizar el filtro, ya que las otras clases no muestran mayor relevancia en la cantidad de datos.

Se emplea loc [] este indexador se utiliza para seleccionar y filtrar datos del DataFrame basándose en etiquetas de los vehículos, a continuación, se gráfica esta información para tener una mejor visualización de la cantidad de estos vehículos por clase de vehículos.

```
0 s ▶ clase_contar_filtrado = clase_contar.loc[['CAMIONETA', 'AUTOMOVIL', 'CAMPERO', 'MOTOCICLETA']]
clase_contar_filtrado
```

| | count |
|-------------|-------|
| CLASE | |
| CAMIONETA | 1245 |
| AUTOMOVIL | 388 |
| CAMPERO | 328 |
| MOTOCICLETA | 27 |


dtype: int64

```
▼ Distribución Porcentual de Clases de Vehículos en Eje Cafetero</>

0 s ▶ clase_contar = data_eje['CLASE'].value_counts()
colores = ['green', 'yellow', 'magenta', 'blue']

plt.figure(figsize=(8,8))
plt.pie(clase_contar_filtrado.values, labels=clase_contar_filtrado.index, autopct='%1.1f%%',
        startangle=140, colors=colores, shadow = True, explode = [0, 0, 0, 0.1])
plt.title('Distribución Porcentual de Clases de Vehículos en Eje Cafetero')

plt.show()
```



Gráfica 3. Gráfico circular o pie chart de Clase de Vehículos

- Camioneta: 62.6%
- Automóvil: 19.5%
- Campero: 16.5%
- Motocicleta: 1.4%


- La camioneta es el vehículo predominante en la región (62.6%), lo que refleja su importancia para actividades familiares, comerciales y rurales.
- El automóvil ocupa el segundo lugar (19.5%), siendo clave en la movilidad urbana.
- El campero representa el 16.5%, lo que evidencia su utilidad en terrenos montañosos y rurales característicos del Eje Cafetero.
- La motocicleta tiene una participación muy baja (1.4%), lo que contrasta con su alto uso en otros contextos urbanos del país.

Gráfico de líneas que muestra la tendencia del número de vehículos registrados por año en el Eje Cafetero

```
[149] contar_años = data_eje['AÑO_REGISTRO'].value_counts().sort_index()

plt.figure(figsize=(12, 6))
plt.plot(contar_años_filtrado.index, contar_años_filtrado.values, marker='o')
plt.xlabel('Año de Registro')
plt.ylabel('Número de Vehículos')
plt.title('Tendencia del Número de Vehículos Registrados por Año en Eje Cafetero')
plt.xticks(contar_años_filtrado.index)
plt.grid(True, linestyle='--', color = 'green') # muestra o oculta líneas de cuadrícula en un gráfico
for x, y in zip(contar_años_filtrado.index, contar_años_filtrado.values): #Con el for en "zip" se recorre el año y el valor.
    plt.text(x, y + 20, str(y), ha='center', fontsize=9, color="black") #Con el +20 se colocan las etiquetas desplazadas.

plt.show()
```



Gráfica 4. Año de registro y número de vehículos 2018 a 2022

1. 2018 inició bajo

Solo 20 vehículos registrados.

Representa un punto de partida con adopción mínima de este tipo de vehículos.

2. 2019 – Ligero crecimiento

Se registran 81 vehículos, lo que significa un incremento con respecto a 2018.

Aunque la cifra sigue siendo baja, muestra un interés inicial en la adopción que es el año en que es emitida la Ley 1964 de 2019.

3. 2020 – Estabilidad con leve aumento

Con 129 vehículos registrados, el crecimiento fue moderado.

Posiblemente influenciado por la pandemia (COVID-19) que redujo la actividad económica y las compras.

4. 2021 – Crecimiento acelerado

Los registros suben a 637 vehículos, un salto significativo respecto al año anterior.

Este cambio refleja un mayor interés y políticas más favorables hacia la transición energética y movilidad sostenible.

5. 2022 – Consolidación de la tendencia

Se alcanza un máximo de 1101 vehículos registrados.


El crecimiento continúa fuerte respecto a 2021, consolidando la transición hacia vehículos híbridos y eléctricos en la región.

Gráfico de barras que compara el número de vehículos registrados en Risaralda, Caldas y Quindío

```
[150] dpto_contar = data_eje['DEPARTAMENTO'].value_counts()

plt.figure(figsize=(10, 6))
barras = plt.bar(dpto_contar.index, dpto_contar.values, color = "green", alpha = 0.5)
plt.xlabel('Departamento')
plt.ylabel('Número de Vehículos')
plt.title('Número de Vehículos Registrados por Departamento en Eje Cafetero')
plt.grid(axis='y', linestyle='--', color= 'green')
plt.bar_label(barras, padding=3)

plt.show()
```



Gráfica 5. Departamento vs número de vehículos 2018 a 2022

Datos observados en la gráfica:

- Risaralda: 958 vehículos
- Caldas: 750 vehículos
- Quindío: 304 vehículos

1. Risaralda – Mayor participación: Esto puede deberse a su mayor desarrollo económico, población urbana más concentrada y posiblemente un buen conocimiento de las políticas nacionales que incentivan la movilidad sostenible.

2. Caldas – Segundo lugar con fuerza: Tiene una participación importante, la diferencia con Risaralda no es tan grande, lo que indica que ambos departamentos muestran una fuerte adopción de vehículos híbridos y eléctricos.


3. Quindío – Menor participación: Esto sugiere menor penetración del mercado de vehículos sostenibles, posiblemente por factores como: menor tamaño poblacional, ingresos promedio más bajos o desconocimiento de los incentivos nacionales.

Gráfico de barras que muestra la distribución de los tipos de combustible en el Eje Cafetero

```
[152] fuel_counts = data_eje['COMBUSTIBLE'].value_counts()

plt.figure(figsize=(10, 6))
barras = plt.bar(fuel_counts.index, fuel_counts.values, color = "green", alpha = 0.5)
plt.xlabel('Tipo de Combustible')
plt.ylabel('Número de Vehículos')
plt.title('Distribución de Tipos de Combustible en Eje Cafetero')
plt.grid(axis='y', linestyle='--', color= 'green')
plt.bar_label(barras, padding=3)

plt.show()
```



Gráfica 6. Tipo de Combustible vs Número de vehículos 2018 a 2022

1. Predominio de los híbridos gasolina–eléctrico (GASO/ELÉC): Con 1837 unidades indica que en el Eje cafetero los usuarios prefieren vehículos que combinan motor de combustión con eléctrico, debido a:

- Mayor autonomía.
- Menor dependencia de estaciones de carga.
- Accesibilidad económica y mismos beneficios establecidos en la normatividad frente a los 100% eléctricos.

El mercado en el Eje Cafetero está dominado por los híbridos gasolina–eléctricos, los cuales se perciben como una opción de transición hacia la movilidad sostenible.

2. Vehículos 100% eléctricos (ELÉCTRICO): Con 125 unidades su presencia es significativa pero aún baja comparada con los híbridos. Esto refleja las limitaciones actuales de infraestructura de carga en la región y el costo más alto de adquisición.

3. Híbridos diésel–eléctrico (DIÉS/ELÉC): Con apenas 50 unidades, tienen la menor participación. Esto se explica porque la oferta de modelos diésel–eléctricos es reducida en el mercado colombiano y la preferencia de los consumidores se concentra en gasolina–eléctrico.

4. ANÁLISIS DESCRIPTIVO

A continuación, se aplica el filtro sobre DataFrame (data_eje) para que muestren los valores superiores al año 2017 sobre la columna año de registro se obtiene como resultado 1975 registros x 5 columnas.

Se aplica el filtro a "data_eje" para que muestre solo los valores superiores al año 2017 para AÑO_REGISTRO:

```
data_filtrada = data_eje[data_eje["AÑO_REGISTRO"] > 2016]
data_filtrada
```

| | DEPARTAMENTO | CLASE | COMBUSTIBLE | FECHA_REGISTRO | AÑO_REGISTRO |
|-------|--------------|-------------|-------------|------------------------|--------------|
| 37 | Quindío | CAMIONETA | ELECTRICO | 12/03/2020 12:00:00 AM | 2020 |
| 2151 | Quindío | CUADRICICLO | ELECTRICO | 04/22/2019 12:00:00 AM | 2019 |
| 3909 | Quindío | AUTOMOVIL | ELECTRICO | 06/05/2018 12:00:00 AM | 2018 |
| 4109 | Quindío | AUTOMOVIL | ELECTRICO | 07/26/2019 12:00:00 AM | 2019 |
| 4659 | Quindío | CAMIONETA | ELECTRICO | 04/29/2022 12:00:00 AM | 2022 |
| ... | ... | ... | ... | ... | ... |
| 56321 | Risaralda | CAMPERO | GASO ELEC | 11/01/2022 12:00:00 AM | 2022 |
| 56400 | Risaralda | CAMIONETA | GASO ELEC | 10/12/2022 12:00:00 AM | 2022 |
| 56401 | Risaralda | CAMIONETA | GASO ELEC | 10/12/2022 12:00:00 AM | 2022 |
| 56402 | Risaralda | CAMIONETA | GASO ELEC | 10/05/2022 12:00:00 AM | 2022 |
| 56403 | Risaralda | CAMIONETA | GASO ELEC | 10/05/2022 12:00:00 AM | 2022 |

1975 rows x 5 columns

Seguidamente se aplica a la data_filtrada anteriormente el filtro para que solo se muestran la clase de vehículos con datos más representativos estos son: Automóvil, Camioneta, Campero y Motocicleta con un total de 1951 registros x 5 columnas.

Se aplica el filtro a "data_filtrada" para que muestre solo los valores de AUTOMÓVIL, CAMIONETA, CAMPERO Y MOTOCICLETA:

```
# isin es un método que sirve para verificar si cada valor de una columna está dentro de una lista o conjunto de valores.
data_eje_filtrada = data_filtrada[data_filtrada["CLASE"].isin(["AUTOMOVIL", "CAMIONETA", "CAMPERO", "MOTOCICLETA"])]
data_eje_filtrada
```

| | DEPARTAMENTO | CLASE | COMBUSTIBLE | FECHA_REGISTRO | AÑO_REGISTRO |
|-------|--------------|-----------|-------------|------------------------|--------------|
| 37 | Quindío | CAMIONETA | ELECTRICO | 12/03/2020 12:00:00 AM | 2020 |
| 3909 | Quindío | AUTOMOVIL | ELECTRICO | 06/05/2018 12:00:00 AM | 2018 |
| 4109 | Quindío | AUTOMOVIL | ELECTRICO | 07/26/2019 12:00:00 AM | 2019 |
| 4659 | Quindío | CAMIONETA | ELECTRICO | 04/29/2022 12:00:00 AM | 2022 |
| 5742 | Quindío | AUTOMOVIL | ELECTRICO | 01/20/2022 12:00:00 AM | 2022 |
| ... | ... | ... | ... | ... | ... |
| 56321 | Risaralda | CAMPERO | GASO ELEC | 11/01/2022 12:00:00 AM | 2022 |
| 56400 | Risaralda | CAMIONETA | GASO ELEC | 10/12/2022 12:00:00 AM | 2022 |
| 56401 | Risaralda | CAMIONETA | GASO ELEC | 10/12/2022 12:00:00 AM | 2022 |
| 56402 | Risaralda | CAMIONETA | GASO ELEC | 10/05/2022 12:00:00 AM | 2022 |
| 56403 | Risaralda | CAMIONETA | GASO ELEC | 10/05/2022 12:00:00 AM | 2022 |

1951 rows x 5 columns

Se crea una tabla dinámica para mostrar la **desviación estándar** y la **varianza** de los años de registro de vehículos, agrupados por:

- Departamento
- Tipo de combustible

Se implemento una tabla dinámica para mostrar la desviación estándar y la varianza de los años de registro por departamento y tipo de combustible

```
[ ] tabla_din = pd.pivot_table(data_eje_filtrada,
                                index=['DEPARTAMENTO', 'COMBUSTIBLE'],
                                values=['AÑO_REGISTRO'],
                                aggfunc=['std', 'var'])
tabla_din.rename(columns={'std': 'Desviación Estándar', 'var': 'Varianza'},
                  level=0, inplace=True)
tabla_din.rename(columns={'AÑO_REGISTRO': ''},
                  level=1, inplace=True)

tabla_din.columns = tabla_din.columns.set_names([None, 'AÑO DE REGISTRO'])
tabla_din
```

La tabla dinámica permite resumir, agrupar y analizar grandes cantidades de datos de forma eficiente. En este caso, se quiere ver qué tan dispersos son los años de registro dependiendo del departamento y tipo de combustible. Esto es útil para análisis estadísticos o para detectar patrones.

```
tabla_din = pd.pivot_table(data_eje_filtrada,
                             index=['DEPARTAMENTO', 'COMBUSTIBLE'],
                             values=['AÑO_REGISTRO'],
                             aggfunc=['std', 'var'])
```

- **pd. pivot_table**: crea la tabla dinámica.
- **data_eje_filtrada**: es el DataFrame con los datos filtrados.
- **index**: define las categorías por las que se agruparán los datos (DEPARTAMENTO y COMBUSTIBLE).
- **values**: el campo numérico a analizar (AÑO_REGISTRO).
- **aggfunc**: funciones estadísticas a aplicar: desviación estándar (std) y varianza (var).

```
tabla_din.rename(columns={'std': 'Desviación Estándar', 'var': 'Varianza'},
                  level=0, inplace=True)
```

Se renombra el primer nivel de columnas para que sea más claro:

std → **Desviación Estándar**, **var** → **Varianza**.

```
tabla_din.rename(columns={'AÑO_REGISTRO': ''},  
                  level=1, inplace=True)
```

Se elimina el nombre del segundo nivel de columnas, para que se vea más limpio visualmente.

```
tabla_din.columns = tabla_din.columns.set_names([None, 'AÑO DE REGISTRO'])
```

Ajusta los nombres de los niveles de columnas: el primero queda sin nombre, y el segundo se llama "AÑO DE REGISTRO".



The screenshot shows a Jupyter Notebook interface with a dynamic table. The table has four columns: 'DEPARTAMENTO' (Department), 'AÑO DE REGISTRO' (Year of Registration), 'Desviación Estándar' (Standard Deviation), and 'Varianza' (Variance). The rows are grouped by department and fuel type. The departments are Caldas, Quindio, and Risaralda. The fuel types are DIES ELEC, ELECTRICO, and GASO ELEC. The values for standard deviation and variance are displayed for each combination.

| DEPARTAMENTO | AÑO DE REGISTRO | Desviación Estándar | Varianza |
|--------------|-----------------|---------------------|----------|
| Caldas | DIES ELEC | 0.522233 | 0.272727 |
| | ELECTRICO | 1.352467 | 1.829167 |
| | GASO ELEC | 0.867735 | 0.752965 |
| Quindio | DIES ELEC | 0.375534 | 0.141026 |
| | ELECTRICO | 1.760682 | 3.100000 |
| | GASO ELEC | 0.656015 | 0.430356 |
| Risaralda | DIES ELEC | 0.767420 | 0.588933 |
| | ELECTRICO | 1.199085 | 1.437805 |
| | GASO ELEC | 0.735672 | 0.541214 |

Se muestra la tabla dinámica final para cada combinación de departamento y tipo de combustible:

- La **desviación estándar** de los años de registro

- La **varianza** de los años de registro

Esto permite analizar la **dispersión** de los datos por región y tipo de combustible.

A continuación, se procede el promedio móvil por cada dos años:

```
[52] # Cuenta el número de vehículos por año
      cuenta_anual = data_eje_filtrada['AÑO_REGISTRO'].value_counts().sort_index()

      # Calcula el promedio móvil cada 2 años
      promedio_movil = cuenta_anual.rolling(window=2).mean()

      print("Promedio móvil de 2 años de vehículos matriculados:")
      print(promedio_movil)
```

```
➡ Promedio móvil de 2 años de vehículos matriculados:
AÑO_REGISTRO
2018         NaN
2019         47.0
2020        100.0
2021        376.5
2022        865.0
Name: count, dtype: float64
```

value_counts (): cuenta cuántos registros (vehículos) hay por cada año.

sort_index (): ordena los años en orden cronológico (por defecto, value_counts los ordena de mayor a menor frecuencia).

Se usa una **ventana deslizando de 2 años** para calcular el promedio entre años consecutivo; De esta manera:

| Año | Promedio Móvil de 2 Años |
|------|-----------------------------|
| 2018 | NaN |
| 2019 | $(2018 + 2019) / 2 = 47$ |
| 2020 | $(2019 + 2020) / 2 = 100$ |
| 2021 | $(2020 + 2021) / 2 = 376.5$ |
| 2022 | $(2021 + 2022) / 2 = 865$ |

Nota: El primer año (2018) aparece con valor NaN porque no hay un año anterior para calcular el promedio. Se muestra cómo ha cambiado la tendencia de matriculación de vehículos año a año, suavizando picos o caídas bruscas.

5. INTERPRETACIÓN DE RESULTADOS

TENDENCIA CRECIENTE

- El promedio móvil aumenta significativamente de 47 (en 2019) a 865 (en 2022).
- Esto indica que cada vez se están registrando más vehículos año tras año.

CRECIMIENTO ACELERADO

- De 2019 a 2020, el promedio sube ligeramente: de **47 → 100**.
- Pero luego crece mucho más rápido:
 - 2020 a 2021: **100 → 376.5**
 - 2021 a 2022: **376.5 → 865**

Influencia de la Ley 1964 de 2019 (Colombia)

La Ley 1964 de 2019 fue promulgada en Colombia con el objetivo de promover el uso de vehículos eléctricos e híbridos, estableciendo incentivos importantes como:

- Reducción del impuesto vehicular (hasta el 1%)
- Exención parcial o total del pico y placa
- Descuentos en peajes
- Beneficios en parqueaderos públicos
- Prioridad en registro y matrícula

Relación entre la ley y los datos observados

Punto de cambio: Año 2019

- Aunque el promedio móvil en 2019 fue bajo (47 vehículos), la ley se aprobó ese mismo año, y sus efectos empezaron a notarse progresivamente.

EFFECTO ACUMULADO EN 2020-2022

- El fuerte aumento a partir de 2020 (promedio de 100) y sobre todo en 2021 y 2022 (hasta 865) puede estar directamente relacionado con:
 - Mayor interés de los ciudadanos en aprovechar los beneficios
 - Aumento de la oferta de vehículos eléctricos e híbridos
 - Campañas de gobierno y sector privado que promueven la movilidad sostenible.

CAMBIO EN EL COMPORTAMIENTO DEL MERCADO

- Estos beneficios no sólo estimularon las ventas, sino también cambiaron las preferencias de los consumidores.

CONCLUSIÓN CON ENFOQUE NORMATIVO

El análisis del promedio móvil de vehículos matriculados entre 2019 y 2022 evidencia un crecimiento notable que coincide con la promulgación de la **Ley 1964 de 2019**, la cual incentivó significativamente la adopción de vehículos eléctricos e híbridos en Colombia. Este marco normativo parece haber sido un catalizador clave para el cambio en la dinámica del registro vehicular, especialmente a partir del año 2020, consolidándose en 2021 y 2022 como una **tendencia sostenida de transición hacia la movilidad sostenible**.

Se crea código para generar un gráfico de línea y así visualizar el promedio móvil de 2 años del número de vehículos registrados, usando matplotlib.


```
plt.figure(figsize=(10, 6))
plt.plot(promedio_movil.index, promedio_movil.values, marker='o', linestyle='--')
plt.xlabel('Año de Registro')
plt.ylabel('Promedio Móvil de Vehículos Registrados (2 años)')
plt.title('Promedio Móvil de 2 años de Vehículos Registrados por Año en Eje Cafetero')
plt.xticks(promedio_movil.index)
plt.grid(True, linestyle='--', color = 'green')

for x, y in zip(promedio_movil.index[1:], promedio_movil.values[1:]):
    plt.text(x, y, f'{y:.1f}', ha='center', va='bottom')

plt.show()
```

El gráfico permite:

- Observar la tendencia temporal en el número de vehículos registrados.
- Suavizar fluctuaciones año a año usando el promedio móvil.
- Facilitar la comparación entre años consecutivos.
- Destacar visualmente el crecimiento o disminución de las matrículas.



Gráfica 7. Promedio Móvil por años 2018 a 2022

Este gráfico muestra la evolución del promedio móvil del número de vehículos registrados en el Eje Cafetero durante estos años.

- Aumento progresivo y sostenido: Se observa un crecimiento fuerte y constante en los valores del promedio móvil a partir de 2020.
- Despegue evidente en 2021 y 2022: El aumento es más pronunciado a partir de 2021, lo que sugiere un cambio estructural en el mercado, posiblemente influido por incentivos normativos.
- Ley 1964 de 2019 como catalizador
- El crecimiento coincide con la implementación de beneficios para vehículos eléctricos e híbridos establecidos en la Ley 1964 (2019), que comenzó a impactar el mercado desde el año 2020-2021.

- Esto pudo haber estimulado tanto el interés del consumidor como las estrategias de comercialización de vehículos más sostenibles.
- La caída en 2019 es relativa
 - El valor de 2019 es bajo, pero es esperable porque solo promedia dos años iniciales (uno de ellos con pocos datos).
 - A partir de 2020, la curva empieza a reflejar el verdadero comportamiento creciente del mercado.

Conclusión general: El gráfico de promedio móvil de 2 años permite visualizar claramente una tendencia creciente en el registro de vehículos en el Eje Cafetero, especialmente a partir del año 2020. Esta tendencia es coherente con el contexto normativo nacional (Ley 1964 de 2019) que fomentó la movilidad eléctrica e híbrida. Así, el gráfico no solo muestra una evolución numérica, sino que refleja un cambio estructural en las políticas y comportamientos de movilidad en la región.

▼ **Análisis de Correlación y Asociación, para ver combinaciones frecuentes.**

```
pd.crosstab(data_eje_filtrada['CLASE'], data_eje_filtrada['COMBUSTIBLE'])
```

| | COMBUSTIBLE | DIES | ELEC | ELECTRICO | GASO | ELEC |
|-------------|-------------|------|------|-----------|------|------|
| CLASE | | | | | | |
| AUTOMOVIL | | 0 | 24 | 346 | | |
| CAMIONETA | | 47 | 33 | 1163 | | |
| CAMPERO | | 0 | 0 | 328 | | |
| MOTOCICLETA | | 0 | 6 | 0 | | |

Esto crea una tabla cruzada (crosstab) que:

- Cuenta cuántas veces aparece cada combinación de CLASE y COMBUSTIBLE.
- Ayuda a detectar combinaciones frecuentes o patrones dominantes.

Gasolina_Electrico domina completamente:

- Es el tipo de combustible más común en todas las clases.

- Muy frecuente en camionetas (1163), automóviles (346), y camperos (328).

Vehículos Diesel_Electrico solo en camionetas:

- 47 registros → puede indicar un mercado o flota específica de camionetas híbridas diésel.

Motocicletas eléctricas empiezan a aparecer:

- Aunque en pequeña cantidad (6), ya hay presencia → tendencia interesante para movilidad sostenible urbana.

Eléctricos puros (ELÉCTRICO):

- Están presentes en todas las clases, pero en números más bajos.
- Podría reflejar una adopción inicial de tecnologías 100% eléctricas, que aún no supera a los híbridos.

Esta tabla cruzada permite analizar las combinaciones más frecuentes entre clase de vehículo y tipo de combustible, revelando que los vehículos híbridos de gasolina (GASO ELEC) dominan el parque vehicular analizado, especialmente en camionetas. También muestra la incipiente presencia de eléctricos puros, destacando una transición tecnológica en curso en la región evaluada.


Se crea código para generar mapa de calor (heatmap) es ideal para visualizar este tipo de datos cruzados, porque muestra de forma rápida cuáles combinaciones son más frecuentes mediante colores (más oscuro = mayor cantidad).

```
import seaborn as sns
import matplotlib.pyplot as plt
import pandas as pd

# Generar tabla cruzada
tabla_cruzada = pd.crosstab(data_eje_filtrada['CLASE'], data_eje_filtrada['COMBUSTIBLE'])

# Crear mapa de calor
plt.figure(figsize=(10, 6))
sns.heatmap(tabla_cruzada, annot=True, fmt='d', cmap='YlGnBu', linewidths=0.5)

# Personalización del gráfico
plt.title('Mapa de Calor: Frecuencia de Vehículos por Clase y Combustible')
plt.xlabel('Tipo de Combustible')
plt.ylabel('Clase de Vehículo')
plt.tight_layout()
plt.show()
```



Gráfica 8. Mapa de calor frecuencia de vehículos por clase y combustible

El mapa de calor refuerza la observación de que el tipo de tecnología híbrida más adoptada es **GASO ELEC**, especialmente en camionetas, lo que puede estar relacionado con incentivos fiscales y operativos promovidos por la Ley 1964 de 2019. El mercado eléctrico puro aún está en desarrollo, con adopción incipiente en todas las clases de vehículos.

▼ Porcentaje de diferencia de crecimiento entre años

```
[55] crecimiento = contar_años_filtrado.pct_change() * 100
      print(crecimiento)
```

```

AÑO_REGISTRO
2018         NaN
2019    305.000000
2020     59.259259
2021    393.798450
2022     72.841444
Name: count, dtype: float64

```

| Año | % Crecimiento Anual |
|------|----------------------------------|
| 2018 | NaN (<i>no hay año previo</i>) |
| 2019 | 305.00% |
| 2020 | 59.26% |
| 2021 | 393.80% |
| 2022 | 72.84% |

El porcentaje de crecimiento entre años muestra una **tendencia creciente muy marcada** en los registros de vehículos, particularmente a partir de 2019. Esto coincide con la implementación de políticas como la **Ley 1964 de 2019**, que impulsó el uso de vehículos eléctricos e híbridos. El crecimiento del **393% en 2021** sugiere un punto de inflexión, posiblemente relacionado con una **acumulación de demanda post pandemia**, mayor oferta de vehículos, e incentivos activos.

Se crea código para visualizar rápidamente cómo ha cambiado el número de registros por año, el cual ayuda a detectar:


- Años con mayor crecimiento
- Periodos de caída o estancamiento

▼ Gráfico con la tendencia del Número de Vehículos Registrados por Año en Eje Cafetero

```
[57] contar_años1 = data_eje_filtrada['AÑO_REGISTRO'].value_counts().sort_index()

plt.figure(figsize=(12, 6))
plt.plot(contar_años1.index, contar_años1.values, marker='o')
plt.xlabel('Año de Registro')
plt.ylabel('Número de Vehículos')
plt.title('Tendencia del Número de Vehículos Registrados por Año en Eje Cafetero')
plt.xticks(contar_años1.index)
plt.grid(True, linestyle='--', color = 'green') # muestra o oculta líneas de cuadrícula en un gráfico
for x, y in zip(contar_años1.index, contar_años1.values): #Con el for en "zip" se recorre el año y el valor.
    plt.text(x, y + 20, str(y), ha='center', fontsize=9, color="black") #Con el +20 se colocan las etiquetas desplazadas.

plt.show()
```

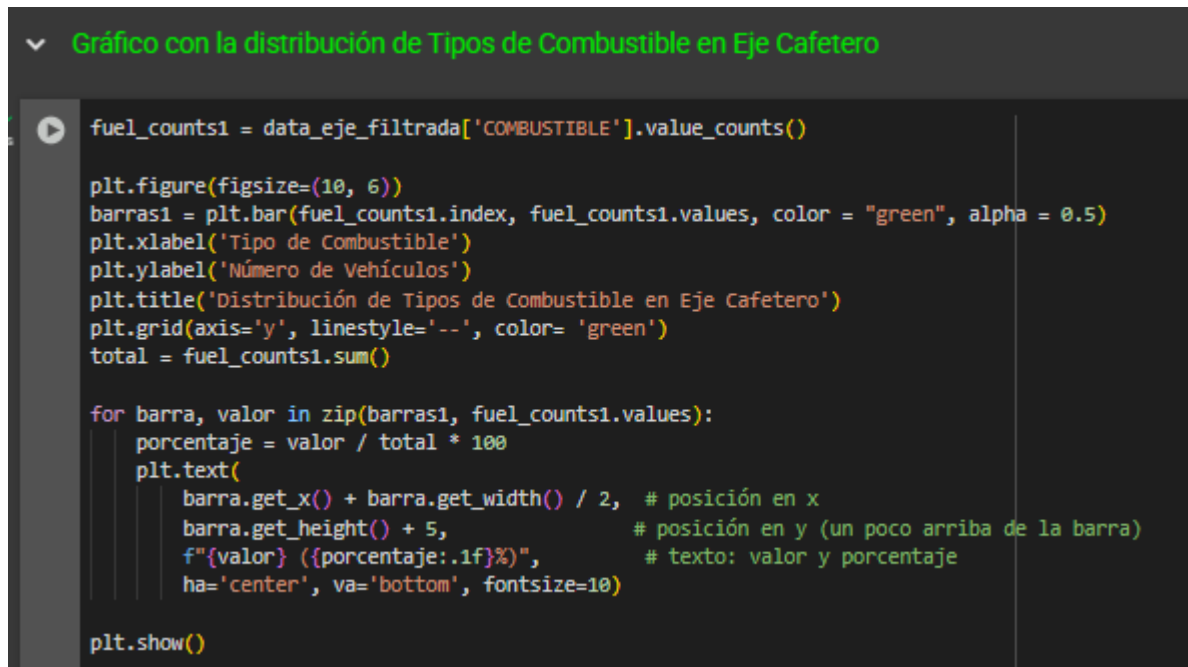


Gráfica 9. Tendencia del Número de vehículos Registrados por año

| Año | Vehículos registrados (estimado por tus datos anteriores) |
|------|---|
| 2018 | Bajo (base inicial) |
| 2019 | Aumento fuerte (Ley 1964 impacta) |
| 2020 | Aumento moderado |
| 2021 | Pico alto (mayor crecimiento) |
| 2022 | Sigue alto, pero leve desaceleración |

- Tendencia general creciente entre 2018 y 2022.
- El mayor salto ocurre en 2021, lo que puede estar relacionado con: Implementación plena de beneficios de la Ley 1964 de 2019.
- 2022 muestra crecimiento, pero no tan drástico, podría significar una fase de estabilización del mercado.


Este gráfico muestra de manera clara cómo ha evolucionado el número de vehículos registrados en el Eje Cafetero en los últimos años. La fuerte tendencia al alza desde 2019 sugiere un cambio estructural impulsado por políticas públicas (como la Ley 1964), mayor conciencia ambiental, e innovación tecnológica en movilidad eléctrica e híbrida. Esta visualización es clave para evidenciar el impacto positivo de la legislación y las tendencias de adopción sostenible.



Se crea este código para generar una gráfica de barras y visualizar la distribución de los tipos de combustible utilizados por los vehículos registrados en el Eje Cafetero.

El objetivo principal es: Identificar cuáles tecnologías de combustible (eléctrico, híbrido, diésel, etc.) son más comunes entre los vehículos registrados en la región.

La gráfica de barras muestra que los vehículos híbridos de gasolina (GASO ELEC) son los más frecuentes en la región del Eje Cafetero, posiblemente a su costo más bajo comparado con los híbridos Diesel (DIES ELEC). A pesar de que los vehículos eléctricos puros aún son minoría, su presencia ya se registra y está en crecimiento.



Gráfica 10. Distribución de Tipos de Combustible

Se crea un código que genera una gráfica de barras para mostrar la distribución de las clases de vehículos registrados en el Eje Cafetero.

Gráfico con la distribución de Clases de Vehículos en Eje Cafetero


```
plt.figure(figsize=(6, 6))
clase_vehiculo = data_eje_filtrada['CLASE'].value_counts()

barras2 = plt.bar(clase_vehiculo.index, clase_vehiculo.values, color = "green", width = 0.8, alpha = 0.5)
plt.xlabel('Clase de Vehículo')
plt.ylabel('Número de Vehículos')
plt.title('Distribución de Clases de Vehículos en Eje Cafetero')
plt.xticks(rotation=45, ha='right')
plt.grid(axis='y', linestyle='--', color= 'green')
plt.tight_layout() #Ajustar el diseño para evitar que las etiquetas se superpongan

total = clase_vehiculo.sum()

for barra, valor in zip(barras2, clase_vehiculo.values):
    porcentaje = valor / total * 100
    plt.text(barra.get_x() + barra.get_width() / 2, # posición en x
             barra.get_height() + 5, # posición en y (un poco arriba de la barra)
             f"{valor} ({porcentaje:.1f})%", # texto: valor y porcentaje
             ha='center', va='bottom', fontsize=10)

plt.show()
```



Gráfica 11. Distribución de clases de vehículos en el Eje Cafetero

Muestra la distribución total por tipo de vehículo.

Nos permite identificar qué clase de vehículos lidera el parque automotor registrado.

- **Camioneta:** clase más registrada.
- **Automóvil:** segunda clase más frecuente.
- **Campero y Motocicleta:** muy por debajo.

Camionetas dominan el registro, lo cual puede deberse a:

- Su uso mixto (personal y empresarial).
- Mayor capacidad de adaptación a la topografía del Eje Cafetero.

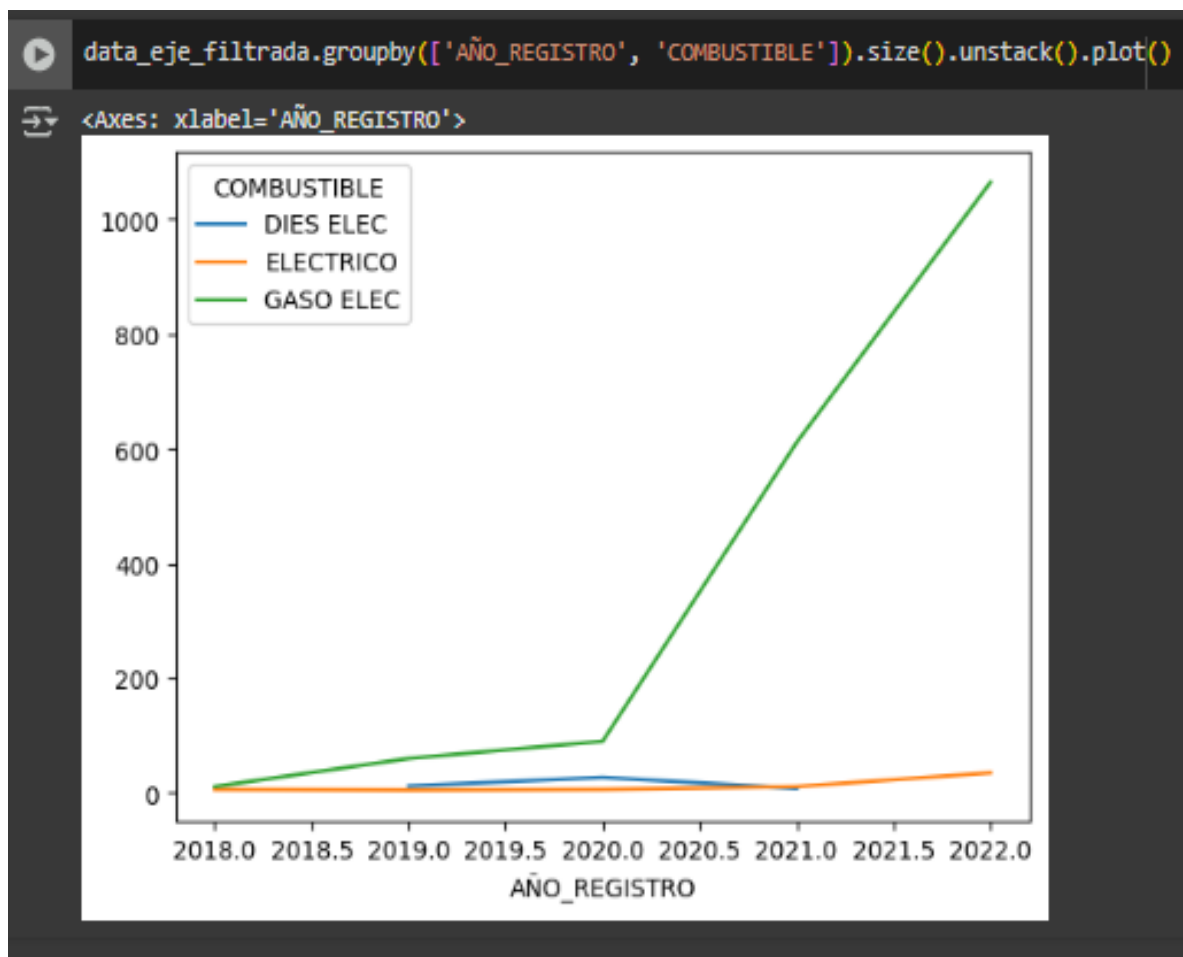
Automóviles también son comunes, probablemente en zonas urbanas.

Camperos podrían tener relevancia rural, pero en menor cantidad.

Motocicletas aparecen en menor medida en estos registros (según el data set filtrado).

Se genera código para gráfica de tendencia entre Año de registro y Combustible

- Agrupa los datos por **año de registro** (AÑO_REGISTRO) y **tipo de combustible** (COMBUSTIBLE).
- .size () cuenta cuántos vehículos hay por cada combinación año-combustible.
- .unstack () convierte la variable COMBUSTIBLE en columnas, para facilitar la gráfica.
- .plot () genera una **gráfica de líneas múltiples**, una por cada tipo de combustible.



Gráfica 12. Gráfico de tendencia entre año de registro y combustible

Se puede observar en el gráfico que:

- **GASO ELEC (línea verde):** Tiene un crecimiento explosivo desde 2020 a 2022. En 2022 supera los 1.000 registros, siendo la opción dominante.
- **ELÉCTRICO (naranja):** Muestra un crecimiento lento pero constante, comenzando desde casi cero en 2018 hasta cerca de 100 registros en 2022.
- **DIES ELEC (azul):** Se mantiene estable y bajo, con muy poco cambio a lo largo del tiempo.

La gráfica muestra una clara preferencia por vehículos híbridos gasolina-eléctrico en el Eje Cafetero, especialmente a partir de 2020. Esta tendencia coincide con la implementación de incentivos gubernamentales establecidos en la **Ley 1964 de 2019**, que promueve el uso de tecnologías limpias. Aunque los eléctricos puros crecen más lentamente, muestran señales de expansión. La electrificación del parque automotor está en marcha, liderada por soluciones híbridas.

Si se tiene en cuenta el mercado general a nivel nacional, se identifican factores clave que motivan la compra de vehículos híbridos de gasolina, como lo es un menor costo inicial vs un vehículo diésel híbrido y la oferta disponible, ya que los vehículos híbridos Diesel generalmente están disponibles en marcas premium, como Volvo, Mercedes, BMW y Land Rover, lo que implica un mayor costo en cuanto a compra y mantenimiento.

Unidades por mes registradas en el eje cafetero utilizando el promedio móvil

Considerando que la columna "FECHA_REGISTRO" indica el año y el mes de registro, procedemos a extraer el número del mes:

```
Para analizar los datos por mes, necesitaríamos extraer la información del mes y el año de la columna FECHA_REGISTRO y luego agrupar por esa nueva columna
```

```
# Cuenta el número de vehículos por año
data_eje_filtrada['FECHA_REGISTRO'] = pd.to_datetime(data_eje_filtrada['FECHA_REGISTRO'])
data_eje_filtrada['AÑO_MES'] = data_eje_filtrada['FECHA_REGISTRO'].dt.to_period('M')

cuenta_mensual = data_eje_filtrada['AÑO_MES'].value_counts().sort_index()

data_eje_filtrada['MES_REGISTRO'] = data_eje_filtrada['FECHA_REGISTRO'].dt.month #Aquí sacamos una columna dedicada a contar el mes

# Calcula el promedio móvil cada 2 meses
promedio_movil_mensual = cuenta_mensual.rolling(window=2).mean()

print("Promedio móvil de 2 meses de vehículos matriculados:")
print(promedio_movil_mensual)
```

➔ Promedio móvil de 2 meses de vehículos matriculados:

| AÑO_MES | |
|---------|------|
| 2018-03 | NaN |
| 2018-05 | 2.0 |
| 2018-06 | 2.5 |
| 2018-08 | 1.5 |
| 2018-10 | 2.5 |
| 2018-11 | 4.5 |
| 2018-12 | 3.0 |
| 2019-02 | 6.0 |
| 2019-03 | 8.0 |
| 2019-04 | 4.0 |
| 2019-05 | 4.5 |
| 2019-06 | 4.5 |
| 2019-07 | 3.0 |
| 2019-08 | 2.0 |
| 2019-09 | 2.0 |
| 2019-10 | 4.0 |
| 2019-11 | 11.0 |
| 2019-12 | 18.5 |
| 2020-01 | 15.0 |
| 2020-02 | 8.0 |
| 2020-03 | 6.0 |
| 2020-05 | 5.0 |
| 2020-06 | 4.0 |
| 2020-07 | 6.5 |
| 2020-08 | 7.5 |
| 2020-09 | 7.5 |
| 2020-10 | 10.5 |
| 2020-11 | 17.0 |
| 2020-12 | 28.5 |
| 2021-01 | 31.5 |

En este caso se han agregado dos columnas, “AÑO_MES” y “MES_REGISTRO”.

✓ [83] data_eje_filtrada

0 s

➔

| | DEPARTAMENTO | CLASE | COMBUSTIBLE | FECHA_REGISTRO | AÑO_REGISTRO | AÑO_MES | MES_REGISTRO |
|-------|--------------|-----------|-------------|----------------|--------------|---------|--------------|
| 37 | Quindio | CAMIONETA | ELECTRICO | 2020-12-03 | 2020 | 2020-12 | 12 |
| 3909 | Quindio | AUTOMOVIL | ELECTRICO | 2018-06-05 | 2018 | 2018-06 | 6 |
| 4109 | Quindio | AUTOMOVIL | ELECTRICO | 2019-07-26 | 2019 | 2019-07 | 7 |
| 4659 | Quindio | CAMIONETA | ELECTRICO | 2022-04-29 | 2022 | 2022-04 | 4 |
| 5742 | Quindio | AUTOMOVIL | ELECTRICO | 2022-01-20 | 2022 | 2022-01 | 1 |
| ... | ... | ... | ... | ... | ... | ... | ... |
| 56321 | Risaralda | CAMPERO | GASO ELEC | 2022-11-01 | 2022 | 2022-11 | 11 |
| 56400 | Risaralda | CAMIONETA | GASO ELEC | 2022-10-12 | 2022 | 2022-10 | 10 |
| 56401 | Risaralda | CAMIONETA | GASO ELEC | 2022-10-12 | 2022 | 2022-10 | 10 |
| 56402 | Risaralda | CAMIONETA | GASO ELEC | 2022-10-05 | 2022 | 2022-10 | 10 |
| 56403 | Risaralda | CAMIONETA | GASO ELEC | 2022-10-05 | 2022 | 2022-10 | 10 |

1947 rows × 7 columns

Se genera un nuevo código para mostrar en gráfico de líneas el volumen de registros por mes en los últimos 5 años:


▼ Consolidado registro por mes de los últimos 5 años

Aquí se puede observar cuáles son los meses del que tienden a tener mayores ventas, en este caso el mes 10 y 11.

```
contar_años10 = data_eje_filtrada['MES_REGISTRO'].value_counts().sort_index()

plt.figure(figsize=(12, 6))
plt.plot(contar_años10.index, contar_años10.values, marker='o')
plt.xlabel('Mes de Registro')
plt.ylabel('Número de Vehículos')
plt.title('Tendencia del Número de Vehículos Registrados por mes en los últimos 5 años en Eje Cafetero')
plt.xticks(contar_años10.index)
plt.grid(True, linestyle='--', color='green') # muestra o oculta líneas de cuadrícula en un gráfico
for x, y in zip(contar_años10.index, contar_años10.values): #Con el for en "zip" se recorre el año y el valor.
    plt.text(x, y + 20, str(y), ha='center', fontsize=9, color='black') #Con el +20 se colocan las etiquetas desplazadas.

plt.show()
```



Gráfica 13. Tendencia de Número de Vehículos Registrados por mes

Aquí generamos un plot contando todos los valores de MES_REGISTRO para identificar tendencias de registro por mes.

De acuerdo al gráfico anterior, se evidencia que a partir del mes 4 (abril) hasta el mes 11 (noviembre) se generan los mayores registros de vehículos, con una disminución en el mes 9 (septiembre).


El mes 10 (octubre) es el mes que más registro se genera, en este caso 235 registros de vehículos en el eje cafetero, siendo el caso opuesto para el mes 01 (enero y febrero) donde posiblemente la reducción también obedece a factores económicos generales, ya que muchas personas enfocan sus gastos para familia en diciembre, y estudios e impuestos para inicio de año.

A continuación, se genera un mapa de calor utilizando seaborn para visualizar el comportamiento de registro para cada año y por mes:

✓ Mapa de calor utilizando seaborn donde se muestra el volumen de registros por años y por cada mes.

```
[56] g= sns.jointplot(data_eje_filtrada, x = "AÑO_REGISTRO", y = "MES_REGISTRO", kind = "hex")
      sns.set_palette("icefire")
      plt.show()
```

En este mapa de calor se puede visualizar el comportamiento de registros durante todos los años para todas las clases de vehículos en el eje cafetero. El comportamiento es como se ha descrito anteriormente donde se evidencia un alto crecimiento de registros en los últimos años, propulsado por efecto de las leyes y decretos vigentes. Como se puede ver en las barras superiores, el crecimiento tiene un comportamiento alcista hacia los últimos años.



Gráfica 14. Volumen de Registros por Años y por cada mes.

Se puede observar que para los años 2019 y 2020, la mayoría de registros se generaron a final de año. Para el año 2021 se puede observar un inicio lento, posiblemente por efectos post pandemia, pero a mitad de año se puede observar un crecimiento constante hasta cerca del mes 4 del año 2022, donde se evidencia un crecimiento importante en los registros posiblemente motivado por la inclusión del decreto 40-2022 donde se extienden los incentivos fiscales por 10 años más.

CONCLUSIONES

De acuerdo al estudio realizado y las tendencias observadas en las diferentes gráficas, se observa que en los primeros años, donde se inicia la comercialización de vehículos híbridos y eléctricos, 2011 a 2017 se presenta un crecimiento muy lento, el cual se debe a múltiples factores, como el desarrollo inicial de una nueva tecnología (híbridos y eléctricos) por parte de los fabricantes, el poco conocimiento de esta por parte de los interesados, el alto costo inicial y la falta de infraestructura para puntos de carga en el caso de los vehículos eléctricos.

A partir de la implementación de la ley 1116 de 2017, en el mes de junio, se empiezan a notar aumentos paulatinos en los registros de vehículos, el cual incrementó de manera notoria luego de la ley 1964 de 2019 donde a final del mismo año se nota un aumento importante en los registros de vehículos.

Dado lo anterior, es claro que las leyes implementadas a favor de la electrificación y cuidado del medio ambiente han jugado un papel muy importante en el crecimiento de estas tecnologías, motivando la adquisición de este tipo de vehículos a los diferentes usuarios.

La preferencia de los usuarios para esta región, se encuentra en los vehículos particulares de tipo “Camioneta”, posiblemente por su versatilidad y practicidad para la topografía de la zona.

RECOMENDACIONES

En la zona del eje cafetero, a pesar de que se cuentan con el incentivo de descuento en impuestos, se evidencia que aún es posible mejorar estos, ya que, a comparación de Cundinamarca y Antioquia, no se evidencian incentivos para uso de parqueaderos (sitios


preferenciales) y se encuentran muy pocos puntos de carga en las ciudades principales y cercanías para vehículos totalmente eléctricos.

Para la zona del eje cafetero, se recomienda utilizar diferentes medios como radio y redes sociales para masificar la información sobre los beneficios actuales al adquirir vehículos eléctricos y/o híbridos.

Promover los vehículos eléctricos, aunque los vehículos híbridos gasolina-eléctrico son los más comunes, el análisis de crecimiento muestra un aumento en los vehículos eléctricos. Continuar promoviendo los vehículos eléctricos y mejorar la infraestructura de carga es crucial para una transición más limpia.

Investigar los factores que impulsan o limitan la adopción: Para entender mejor por qué ciertos meses o años muestran picos de crecimiento, sería valioso investigar eventos específicos (como la implementación de incentivos, cambios en la ley, disponibilidad de modelos o fluctuaciones en los precios del combustible) y cómo influyen en la decisión de compra.

Actualmente el panorama de venta de vehículos híbridos y eléctricos en Colombia continúa creciendo fuertemente, a continuación, se muestra un registro de unidades vendidas a nivel nacional:



Los registros hasta el año 2022 están disponibles en la base de datos de estudio del presente proyecto. Los valores para los años 2023 y 2024 son aproximados de diferentes sitios web, como ifmnoticias.com y revista Motor. Hasta la fecha no se cuenta con una base de datos pública con la cual se pueda realizar un análisis más actualizado, este último aspecto de falta de base de datos en diferentes campos en el país está pendiente de ampliarse y mejorar.

Link al archivo de Jupyter Notebook- Colab

https://colab.research.google.com/drive/1_I6d2tE05aV69yOdN8NL3-4k8sr48EN?authuser=1

Link al GitHub

<https://github.com/ValenC25/Proyecto-Datos-que-Impulsan-la-Transicion>